

Analiza danych: Chicago Taxi Trips

Google BigQuery

1. Wstępne sprawdzenie danych

```
SELECT *
FROM `bigquery-public-data.chicago_taxi_trips.taxi_trips`
LIMIT 10;
```

unique_key	taxi_id	trip_start_timestamp	trip_end_timestamp	trip_seconds	trip_miles	pickup_census_tract	dropoff_census_tract
b99416692f5bc0	8dd990653cc27f	2019-05-29 18:00:00	2019-05-29 18:30:00	1500	1,5		
b99887012c8be1	d156d4adff01ad	2019-05-20 19:10:00	2019-05-20 19:30:00	506	1,67		
b98b6b7afe1f80	beefd3462e3f5a	2019-05-08 00:00:00	2019-05-08 00:00:00	60	0		
b9865af3673441	ef249ea2c31ccb	2019-05-07 16:30:00	2019-05-07 17:00:00	1122	2,86		
e04dbd9a8ba72	45002471b85d6	2013-05-16 08:15:00	2013-05-16 08:15:00	0	0		
b997997e971c0	fa0a84435b292f	2019-05-24 13:10:00	2019-05-24 13:10:00	240	1,4		
b989b45f0f49b6	8423aff4ae5515	2019-05-08 09:40:00	2019-05-08 09:40:00	473	0,85		
b9929c0895146	9b2a23587b25fe	2019-05-24 05:40:00	2019-05-24 06:30:00	2518	17,89		
b987f48069fbdff	54044c4ce47d5	2019-05-01 19:00:00	2019-05-01 20:00:00	2880	18		
b9958c55b8d38	b75e4a5f5666b6	2019-05-07 18:00:00	2019-05-07 18:00:00	540	2,1		

pickup_community	dropoff_community	fare	tips	tolls	extras	trip_total	payment_type
		12,25	0,11	0	0	12,36	Credit Card
		8	2	0	0	10,5	Credit Card
		3,25	0	0	0	3,25	Cash
		12,25	0	0	1	13,25	Cash
		24,05	6,01	0	0	30,06	Credit Card
		5,2	0	0	0	5,2	Cash
		6,5	3	0	0	10	Credit Card
		44	8,9	0	0	53,4	Credit Card
		45,75	12,65	0	5	63,4	Credit Card
		7,25	1,5	0	0	8,75	Credit Card

company	pickup_latitude	pickup_longitude	pickup_location	dropoff_latitude	dropoff_longitude	dropoff_location
KOAM Taxi Association						
Chicago Carriage Cab Corp						
Taxi Affiliation Services						
Taxi Affiliation Service Yellow						
Chicago Elite Cab Corp.						
Taxi Affiliation Services						
Taxi Affiliation Service Yellow						
Taxi Affiliation Service Yellow						
Taxicab Insurance Agency, LLC						
Star North Management LLC						

Wyświetlenie 10 pierwszych wierszy pozwoliło poznać ogólną strukturę zbioru oraz wstępnie ocenić jakość danych. Analiza wizualna wyników ujawnia braki danych (puste pola – wartości NULL), które występują między innymi w kolumnach dotyczących dokładnej lokalizacji (np. `pickup\_latitude`, `pickup\_census\_tract`).

2. Sprawdzenie kompletności danych (braki w kolumnach)

```
SELECT
  COUNT(*) AS total_trips,
  ROUND(COUNT(company) * 100.0 / COUNT(*), 1) AS company,
  ROUND(COUNT(payment_type) * 100.0 / COUNT(*), 1) AS payment_type,
  ROUND(COUNT(trip_miles) * 100.0 / COUNT(*), 1) AS trip_miles,
  ROUND(COUNT(tips) * 100.0 / COUNT(*), 1) AS tips,
  ROUND(COUNT(pickup_community_area) * 100.0 / COUNT(*), 1) AS
pickup_community_area,
  ROUND(COUNT(trip_seconds) * 100.0 / COUNT(*), 1) AS trip_seconds,
  ROUND(COUNT(fare) * 100.0 / COUNT(*), 1) AS fare,
  ROUND(COUNT(trip_total) * 100.0 / COUNT(*), 1) AS trip_total
FROM `bigquery-public-data.chicago_taxi_trips.taxi_trips`;
```

total_trips	company	payment_type	trip_miles	tips	pickup_commun	trip_seconds	fare	trip_total
213111447	84,2	100	100	100	88,6	99,4	100	100

Powyższe zapytanie sprawdza, jaki procent danych faktycznie nadaje się do późniejszej analizy. Jak widać, największe braki występują w kolumnach `company` (brakuje prawie 16% przypisań do firmy) oraz `pickup\_community\_area` (brakuje ponad 11% informacji o dzielnicy startowej). Pojawia się też drobny brak rzędu 0,6% w czasie trwania przejazdu (`trip\_seconds`). Reszta kluczowych kolumn jest w 100% kompletna.

3. Sprawdzenie duplikatów

```
SELECT
  COUNT(unique_key) AS wszystkie_wiersze,
  COUNT(DISTINCT unique_key) AS unikalne_wiersze
FROM `bigquery-public-data.chicago_taxi_trips.taxi_trips`;
```

wszystkie_wiersze	unikalne_wiersze
213111447	211655459

Analiza wykazała, że liczba rekordów jest większa od liczby unikalnych wartości `unique\_key`, co oznacza występowanie powtarzających się identyfikatorów. Różnica wynosi 1 455 988 rekordów (około 0,68% całego zbioru).

4. Określenie godzin szczytu

```
SELECT
  EXTRACT(HOUR FROM trip_start_timestamp) AS godzina,
  COUNT(*) AS liczba_kursow
FROM `bigquery-public-data.chicago_taxi_trips.taxi_trips`
GROUP BY godzina
ORDER BY liczba_kursow DESC;
```

godzina	liczba_kursow
18	13991385
19	13644286
17	13229438
16	12220114
20	12003322
15	11542893
13	11360033
14	11336957
12	11140833
21	10670022
11	10356048
9	10076096
22	9935269
10	9823235
8	8764806
23	8613140
0	7045806
1	5818288
7	5684394
2	4590603
3	3425193
6	3109477
4	2483411
5	2246398

Godziny popołudniowe, szczególnie w przedziale 16:00-19:00, generują zdecydowanie największą liczbę kursów (może to wynikać z powrotów z pracy lub uczelni). Te zaledwie cztery godziny odpowiadają za prawie 25% całego dobowego ruchu. Porównując skrajności, w godzinie największego szczytu 18:00 zapotrzebowanie na taksówki jest ponad 6-krotnie większe niż nad ranem 5:00. Co ciekawe, z danych wyłania się obraz Chicago jako miasta o bardzo aktywnym życiu nocnym. Liczba kursów o północy (godzina 0:00 ok. 7 mln) jest zauważalnie wyższa niż w trakcie porannych dojazdów (godzina 7:00 ok. 5,6 mln). Wynika to prawdopodobnie z faktu, że rano mieszkańcy chętniej wybierają komunikację miejską, aby uniknąć korków, natomiast w nocy taksówki stają się głównym i najbezpieczniejszym sposobem powrotu do domu.

5. Analiza przychodów (TOP 10)

```
SELECT
  COMPANY AS firma,
  ROUND(SUM(trip_total), 2) AS calkowita_kwota,
  ROUND(SUM(fare), 2) AS przychod_bazowy
FROM `bigquery-public-data.chicago_taxi_trips.taxi_trips`
WHERE company IS NOT NULL
GROUP BY firma
ORDER BY przychod_bazowy DESC;
```

TOP 10 największych firm

firma	calkowita_kwota	przychod_bazowy
Taxi Affiliation Services	697 274 465,39	579 004 873,81
Flash Cab	374 589 812,14	326 630 135,35
Yellow Cab	144 847 016,73	124 003 559,81
Dispatch Taxi Affiliation	145 330 534,94	123 504 903,48
Blue Ribbon Taxi	143 983 711,26	120 378 101,93
Chicago Carriage	142 704 376,31	116 162 624,58
Sun Taxi	142 651 847,98	113 808 906,78
City Service	133 881 292,93	108 418 717,42
Choice Taxi Association	130 609 291,83	108 215 240,96
Medallion Leasing	110 512 217,49	90 878 837,97

W tym zapytaniu celowo rozdzielono całkowitą kwotę transakcji (`trip\_total`) od przychodu bazowego (`fare`), ponieważ opłaty dodatkowe (napiwki, bramki) nie stanowią bezpośredniego zarobku korporacji za przewóz. Analiza dziesięciu największych firm pokazuje wyraźną dominację Taxi Affiliation Services, której przychód bazowy wyniósł około 579 mln USD, czyli niemal dwukrotnie więcej niż drugiego w zestawieniu Flash Cab (około 327 mln USD). Kolejne przedsiębiorstwa osiągnęły przychody bazowe na poziomie od około 91 mln do 124 mln USD, co wskazuje na znacznie bardziej wyrównaną konkurencję w dalszej części rankingu. Oznacza to, że lider rynku wyraźnie przewyższa pozostałych przewoźników pod względem skali działalności, natomiast między firmami z miejsc 3-10 różnice są stosunkowo niewielkie.

TOP 10 najmniejszych firm

3385 - Eman Ca	3102,1	2866,1
American United	2246,3	2245,8
2809 - 95474 C&	2620,05	2153,4
4732 - Maude La	1293,99	1114,36
FlashCab	785,36	785,36
3669 - Jordan Ta	350,46	313,95
0118 - Godfray S	189,55	158,05
3556 - RC Andre	24,75	22,75
DTA Test	10,25	9,75
CMT-Sales	7	7

Na końcu zestawienia znajdują się podmioty osiągające bardzo niskie wartości przychodów, często rzędu pojedynczych lub kilkunastu dolarów. Wśród nich można zauważyć wpisy takie jak „DTA Test” oraz nazwy przypominające identyfikatory lub nazwiska kierowców. Sugeruje to obecność danych testowych, pomocniczych lub podmiotów o marginalnej liczbie wykonanych kursów. Tego typu rekordy mogą wprowadzać szum informacyjny podczas analizy rynku, dlatego w dalszych analizach zasadne jest zastosowanie filtra eliminującego podmioty o bardzo niskich przychodach lub niewielkiej liczbie zrealizowanych przejazdów. Ponownie można również zauważyć problem jakości danych. W zestawieniu występuje nazwa FlashCab zapisana zarówno w formie „Flash Cab”, jak i „FlashCab”, co prowadzi do rozdzielenia danych dotyczących tego samego podmiotu.

6. Analiza średnich parametrów przejazdu

```
SELECT
  ROUND(AVG(trip_seconds), 2) AS sredni_czas_przejazdu,
  ROUND(AVG(trip_miles), 2) AS srednia_odleglosc_przejazdu,
  ROUND(AVG(trip_total), 2) AS sredni_koszt_przejazdu
FROM `bigquery-public-data.chicago_taxi_trips.taxi_trips`;
```

sredni_czas_przejazdu	srednia_odleglosc_przejazdu	sredni_koszt_przejazdu
819,91	3,49	16,43

Z danych wynika, że średni czas trwania przejazdu taksówką w Chicago to nieco ponad 13,5 minuty (ok. 820 sekund). W tym czasie pasażerowie pokonują średnio odległość 3,5 mili, a całkowity koszt takiej usługi wynosi średnio nieco ponad 16 dolarów. To daje szybki i czytelny pogląd na to, jak wygląda typowy, "przeciętny" kurs w tym mieście.

7. Segmentacja przejazdów ze względu na odległość

```
SELECT
  CASE
    WHEN trip_miles < 2 THEN 'krotki'
    WHEN trip_miles < 10 THEN 'sredni'
    ELSE 'dlugi'
  END AS typ_kursu,
  COUNT(*) AS liczba_kursow,
  ROUND(AVG(trip_total), 2) AS koszt_przejazdu
FROM `bigquery-public-data.chicago_taxi_trips.taxi_trips`
GROUP BY typ_kursu
ORDER BY liczba_kursow DESC;
```

typ_kursu	liczba_kursow	koszt_przejazdu
krotki	136814126	11,1
sredni	51240335	15,39
dlugi	25056986	47,72

Za pomocą instrukcji warunkowej CASE, podzielono przejazdy na trzy segmenty: krótkie (poniżej 2 mil), średnie (2-10 mil) oraz długie (powyżej 10 mil). Z danych wynika, że w Chicago dominują bardzo krótkie dystanse – stanowią one aż 64,2% wszystkich zrealizowanych kursów. Zgodnie z oczekiwaniami, długie przejazdy generują najwyższe koszty (średnio blisko 48 dolarów). Wynika to bezpośrednio ze stawki za pokonany dystans i czas, a także z faktu, że dłuższe trasy (np. wyjazdy na lotniska) często wiążą się z dodatkowymi opłatami drogowymi.

8. Analiza metod płatności i napiwków

```
SELECT
  ROUND(AVG(tips), 2) AS sredni_napiwek,
  COUNT(*) AS liczba_kursow,
  payment_type AS metoda_platnosci
FROM `bigquery-public-data.chicago_taxi_trips.taxi_trips`
WHERE tips > 0
GROUP BY metoda_platnosci
HAVING COUNT(*) > 10000
ORDER BY sredni_napiwek DESC;
```

sredni_napiwek	liczba_kursow	metoda_platnosci
4,17	164797	Cash
3,84	152636	No Charge
3,8	81041999	Credit Card
3,37	2438801	Mobile
3,02	140704	Prcard
1,81	75387	Unknown

Powyższa analiza skupia się wyłącznie na kursach, w których pasażer zdecydował się zostawić napiwek (zastosowano filtr WHERE tips > 0). Za pomocą HAVING ograniczono wyniki tylko do tych metod, które odnotowały minimum 10 000 transakcji. Z danych wynika, że najwyższe średnie napiwki (4,17 USD) przypisane są do transakcji gotówkowych. Z kolei pod kątem wolumenu, absolutnym dominatorem na rynku jest karta kredytowa, która odpowiada za ponad 95,5% wszystkich ujętych w zestawieniu płatności z napiwkiem.

9. Porównanie kosztów za milę i profilu działalności firm

```
SELECT
  company AS firma,
  COUNT(*) AS liczba_kursow,
  ROUND(SUM(fare) / SUM(trip_miles), 2) AS koszt_zamile,
  ROUND(AVG(trip_miles), 2) AS sredni_dystans,
  ROUND(AVG(fare), 2) AS srednia_oplata
FROM `bigquery-public-data.chicago-taxi-trips.taxi-trips`
WHERE trip_miles > 0
  AND company IS NOT NULL
GROUP BY firma
HAVING COUNT(*) > 10000
ORDER BY koszt_zamile DESC;
```

TOP10 najwyższych kosztów za milę				
firma	liczba_kursow	koszt_zamile	sredni_dystans	srednia_oplata
Blue Ribbon Tax	2438434	23,84	0,75	17,9
Metro Jet Taxi A	111628	6,89	4,8	33,09
3591 - 63480 Ch	26390	4,17	2,29	9,56
Taxi Affiliation Se	27113644	4,13	3,66	15,09
1085 - 72312 N	28405	4,03	2,27	9,13
1469 - 64126 Or	10456	3,98	2,57	10,24
5062 - 34841 Sa	11660	3,96	2,45	9,72
3094 - 24059 G.	18133	3,93	2,42	9,52
5006 - 39261 Sa	20981	3,86	2,78	10,73
4787 - 56058 Re	17859	3,67	2,76	10,15

Powyższe zestawienie porównuje koszty pomiędzy firmami i pokazuje, która z nich osiąga najwyższy średni koszt w przeliczeniu na jedną milę. Znaczna przewaga firmy Blue Ribbon (aż o 17 dolarów za milę więcej niż u konkurencji) wynika z tego, że taksówki tej korporacji pokonują bardzo małe odległości. Średni dystans to zaledwie 0,75 mili, więc tak wysoka cena wynika w dużej mierze z samych opłat stałych (np. przyjazd i opłata początkowa, oczekiwanie kierowcy). Z kolei największą opłatę za cały kurs pobiera Metro Jet Taxi (aż 33 dolary). Jednak ze względu na dalekie dystanse – co w połączeniu z nazwą firmy może nawiązywać do transferów lotniskowych, ich cena za milę nie przekracza 7 dolarów. Wyniki reszty firm na rynku oscylują wokół standardowych 4 dolarów za milę.

TOP10 najniższych kosztów za mile

312 Medallion M	50524	2,87	8	22,93
5874 - 73628 Se	14659	2,85	6,34	18,05
4623 - 27290 Ja	19175	2,81	7,32	20,57
U Taxicab	161545	2,8	8,38	23,43
Petani Cab Corp	14623	2,73	10,19	27,78
Norshore Cab	262674	2,64	3,78	9,99
4053 - 40193 Ad	10703	2,62	9,81	25,75
Chicago Carriag	7978362	2,61	5,51	14,37
3152 - 97284 Cr	11128	2,23	4,36	9,71
303 Taxi	1489155	0,96	8,72	8,35

Powyżej znajduje się to samo zestawienie, ale prezentujące dolną część tabeli. Biorąc pod uwagę, że w analizowanych danych znajdują się aż 83 różne firmy taksówkarskie, pomiędzy TOP 10 najdroższych a najtańszych nie ma wcale gigantycznych rozbieżności. Różnica między stawkami najtańszej firmy z pierwszej dziesiątki (około 3,7 dolara) a najdroższej z ostatniej dziesiątki (około 2,9 dolara) wynosi tak naprawdę zaledwie 0,8 dolara. Z danych wynika, że te z pozoru najtańsze firmy pokonują po prostu znacznie większe odległości. Dzięki temu koszty początkowe (np. za przyjazd) mocno się rozkładają na całej trasie, a ostateczna cena w przeliczeniu na pojedynczą milę jest zauważalnie niższa.

10. Porównanie cen i liczby kursów na przestrzeni lat

```
SELECT
  EXTRACT(YEAR FROM trip_start_timestamp) AS rok,
  COUNT(*) AS liczba_kursow,
  ROUND(AVG(fare), 2) AS srednia_oplata_bazowa,
  ROUND(AVG(trip_total), 2) AS srednia_oplata_calkowita
FROM `bigquery-public-data.chicago_taxi_trips.taxi_trips`
GROUP BY rok
ORDER BY rok ASC;
```

rok	liczba_kursow	srednia_oplata_bazowa	srednia_oplata_calkowita
2013	27223578	12,44	14,27
2014	37395079	12,18	14,15
2015	32385527	12,58	14,83
2016	31756403	13,52	16,03
2017	24979611	13,29	15,96
2018	20731105	13,81	16,8
2019	17926150	14,94	18,23
2020	3888831	15,7	18,37
2021	3947677	20,97	25,09
2022	6382071	21,73	26,83
2023	6495415	22,25	27,74

Powyższe zestawienie analizuje zmiany na rynku taksówkarskim na przestrzeni dekady. Od 2015 roku zarówno średnia opłata bazowa za sam przejazd, jak i opłata całkowita (obejmująca napiwki i opłaty dodatkowe) sukcesywnie rosną, z drobnym spadkiem w 2017 roku. Co ciekawe, liczba realizowanych kursów wykazuje zupełnie odwrotny trend – od 2015 roku zapotrzebowanie na usługi taksówkarskie systematycznie spadało. Największe, wręcz drastyczne załamanie rynku widać między rokiem 2019 a 2020, co wynikało z wybuchu pandemii COVID-19. Liczne obostrzenia, załamanie turystyki oraz masowe przejście na naukę i pracę zdalną mocno pogorszyły sytuację branży. Dopiero od 2021 roku widać pierwsze sygnały odbicia, a liczba zrealizowanych kursów do 2023 roku zaczęła powoli, ale systematycznie rosnąć.

11. Analiza lokalizacji – najlepsze i najgorsze strefy odbioru

```
SELECT pickup_community_area AS lokalizacja_odbioru,
       COUNT(*) AS liczba_kursow
FROM `bigquery-public-data.chicago_taxi_trips.taxi_trips`
WHERE pickup_community_area IS NOT NULL
GROUP BY lokalizacja_odbioru
ORDER BY liczba_kursow DESC;
```

TOP10 najlepsze lokalizacje

lokalizacja_odbioru	liczba_kursow
8	60272017
32	43832881
28	17902644
76	14901501
6	10914862
7	8400293
24	5468418
33	4905222
56	3741178
3	2911264

TOP 10 najgorsze lokalizacje

65	19450
62	18288
54	16545
18	15760
47	15290
63	15078
52	14274
9	13814
55	12007
74	5323

Powyższe zapytanie zestawia najlepsze i najgorsze lokalizacje w Chicago pod kątem liczby generowanych kursów. W bazie danych dzielnice ukryte są pod numerami (tzw. Community Areas). Numery Community Area zostały zinterpretowane zgodnie z oficjalnym podziałem miasta Chicago. Na samej górze z gigantyczną przewagą króluje strefa numer 8, czyli Near North Side, typowe miejsce turystyczne i rozrywkowe miasta, pełne hoteli, restauracji i sklepów. Zaraz za nim znajduje się strefa 32, czyli ściśle biznesowe centrum znane jako Loop. W czołówce, na czwartym miejscu z wynikiem blisko 15 milionów przejazdów, znajduje się też strefa 76, która odpowiada za międzynarodowe lotnisko O'Hare. Wynika z tego jasno, że ruch taksówkarski napędza głównie rozrywka, turystyka, biznes i transfery lotniskowe. Z drugiej strony, patrząc na drugi zrzut ekranu z najslabszymi wynikami (zaledwie po kilkanaście tysięcy kursów przez całą dekadę), można zaobserwować strefy 74 oraz 55, którymi są Mount Greenwood oraz Hegewisch. Są to po prostu mocno oddalone od centrum obrzeża miasta, gdzie mieszkańcy poruszają się własnymi samochodami, a zapotrzebowanie na taksówki jest marginalne.

12. Wpływ pory dnia na czas przejazdu

```
SELECT
  ROUND(AVG(trip_seconds), 2) AS sredni_czas_przejazdu,
  ROUND(AVG(trip_miles), 2) AS sredni_dystans_przejazdu,
  EXTRACT(HOUR FROM trip_start_timestamp) AS godzina
FROM `bigquery-public-data.chicago_taxi_trips.taxi_trips`
GROUP BY godzina
ORDER BY sredni_czas_przejazdu DESC
```

sredni_czas_prz	sredni_dystans_	godzina
989,62	3,61	16
978,3	3,24	17
974,96	3,88	15
932,63	5,7	6
908,34	3,09	18
898,5	3,82	14
875,69	4,03	7
846,24	6,04	5
843,19	3,7	13
839,07	3,29	8
822,99	3,27	19
819,25	3,36	9
813,05	3,66	12
786,68	3,72	11
786,64	3,58	10
769,07	3,49	20
736,82	3,58	21
702,78	3,31	22
674,86	3,12	23
664,54	3,93	4
653,86	3,05	0
614,27	2,71	1
587,85	2,57	3
577,87	2,43	2

Na sam koniec przeanalizowano wpływ pory dnia na średni czas przejazdu. Dzięki zestawieniu średniego czasu trwania przejazdu z pokonywanym dystansem jesteśmy w stanie określić, kiedy w mieście panuje największy ruch. Średni czas przejazdu o godzinie 16:00 to ponad 16,5 minuty (prawie 990 sekund), pomimo że średni dystans wynosi wtedy 3,6 mili. Dla porównania, bardzo podobny dystans (3,58 mili) o godzinie 10:00 czy 21:00 można pokonać w zaledwie 13 minut, czyli średnio o ponad 3 minuty krócej. Z kolei najkrótsze czasy przejazdów notujemy w nocy, między godziną zerową a trzecią nad ranem, co jest naturalnym efektem niskiego natężenia ruchu na drogach.